ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH

BÁO CÁO ĐỒ ÁN MÔN HỌC

(Mã học phần: CO3135)

XÂY DỰNG HỆ THỐNG DỰ ĐOÁN RỦI RO TÍN DỤNG DỰA TRÊN DỮ LIỆU THẺ TÍN DỤNG

Ngành: KHOA HỌC MÁY TÍNH

GVHD: Thầy Huỳnh Văn Thống

SVTH: Phạm Thanh Phong **2212564**
Hoàng Phương Bình **22xxxxx**
Võ Lê Anh Nghĩa **22xxxxx**
Vũ Xuân Chính **22xxxxx**

Thành phố Hồ Chí Minh, tháng 04 năm 2026

MỤC LỤC

1 GIỚI THIỆU **1**
1.1 Lý do thực hiện đề tài 1
1.2 Mục tiêu nghiên cứu 1
1.3 Phạm vi và Giới hạn 2

2 TỔNG QUAN DỮ LIỆU VÀ PHÂN TÍCH KHÁM PHÁ (EDA) **3**
2.1 Mô tả tập dữ liệu 3
2.2 Phân tích phân phối và Tương quan 3
2.2.1 Phân phối biến mục tiêu và Mất cân bằng Lớp (Class Imbalance) 3
2.2.2 Tương quan giữa Các Biến và Vỡ nợ 4
2.2.3 Đa Cộng Tuyến (Multicollinearity) - BILL_AMT và PAY_AMT 4
2.3 Phân tích Các Biến Số Học (Numerical Variables) 5
2.3.1 Thống Kê Mô Tả (Descriptive Statistics) 5
2.3.2 Phân Phối và Outliers 5
2.4 Phân Tích Các Biến Phân Loại (Categorical Variables) 5
2.4.1 Phân Phối Biến Giới Tính (SEX) 5
2.4.2 Phân Phối Biến Học Vấn (EDUCATION) 6
2.4.3 Phân Phối Biến Tình trạng Hôn Nhân (MARRIAGE) 6

3 PHƯƠNG PHÁP NGHIÊN CỨU **7**
3.1 Tiền Xử Lý Dữ Liệu và Làm Sạch 7
3.1.1 Xử Lý Biến Định Danh 7
3.1.2 Xử Lý Trạng Thái Thanh Toán - PAY_0 đến PAY_6 7
3.2 Kỹ Nghệ Đặc Trưng Chuyên Sâu (Feature Engineering) 7
3.2.1 1. Tỷ Lệ Sử Dụng Tín Dụng (Credit Utilization Ratio) 7
3.2.2 2. Tỷ Lệ Thanh Toán (Payment Ratio) 8
3.2.3 3. Tần Suất Chậm Nợ (Late Payment Count) 8
3.3 Giải Quyết Mất Cân Bằng Dữ Liệu bằng SMOTE 8
3.3.1 SMOTE (Synthetic Minority Over-sampling Technique) 8
3.4 Các Metrics Đánh Giá 8

4 KẾT QUẢ VÀ THẢO LUẬN **9**
4.1 Mô hình Boosting và Tối ưu hóa Optuna 9
4.2 Đánh giá và So sánh hiệu năng 9
4.2.1 Tối ưu hóa siêu tham số 9
4.2.2 Nhận xét về kết quả 10
4.3 Phân tích Độ Quan Trọng của Đặc Trưng (Feature Importance) 11
4.3.1 Nhận Xét Chi Tiết 12
4.4 Ma trận nhầm lẫn (Confusion Matrix) 12

5 KẾT LUẬN **13**
5.1 Các Kết Quả Chính 13
5.2 Ứng Dụng Thực Tế 13
5.2.1 Khuyến Nghị Chi Tiết 14
5.3 Giới Hạn và Hạn Chế 14
5.4 Hướng Phát Triển Tiếp Theo 14
5.5 Kết Luận Cuối 15

TÀI LIỆU THAM KHẢO **16**

DANH SÁCH HÌNH VẼ

Hình 2.1 Phân phối biến mục tiêu (Vỡ nợ vs. Không vỡ nợ) - Class Imbalance rất đáng kể 3
Hình 2.2 Ma trận tương quan giữa những biến chính - Thấy rõ đa cộng tuyến trong BILL_AMT và PAY_AMT 5
Hình 2.3 Phân phối của các biến số học chính (Boxplot) - có outliers trong BILL_AMT và PAY_AMT 5

Hình 4.1 Đường cong ROC so sánh các mô hình 11
Hình 4.2 Biểu đồ Feature Importance - late_payment_count chiếm ưu thế 12
Hình 4.3 Ma trận nhầm lẫn của các mô hình tốt nhất 12

DANH SÁCH BẢNG

Bảng 2.1 Top 10 biến có tương quan cao nhất với DEFAULT 4
Bảng 2.2 Thống kê mẫu của những biến chính 5
Bảng 2.3 Phân phối của biến SEX (Giới tính) 5
Bảng 2.4 Phân phối của biến EDUCATION (Trình độ học vấn) 6
Bảng 2.5 Phân phối của biến MARRIAGE (Tình trạng hôn nhân) 6

Bảng 4.1 So sánh hiệu năng giữa các mô hình trên tập kiểm thử 9
Bảng 4.2 So sánh bộ siêu tham số trước và sau khi tối ưu hóa 10
Bảng 4.3 Top 10 Đặc Trưng Theo Feature Importance 11

Bảng 5.1 Khuyến Nghị Model Theo Business Context 14

CHƯƠNG 1
GIỚI THIỆU

1.1 Lý do thực hiện đề tài

Trong bối cảnh nền kinh tế số phát triển mạnh mẽ, các cơ sở tài chính và ngân hàng đang chuyển dịch từ phương thức thẩm định truyền thống sang hệ thống thẩm định tự động dựa trên dữ liệu lớn (Big Data). Rủi ro tín dụng, cụ thể là khả năng khách hàng không thể hoàn trả nợ đúng hạn, là yếu tố sống còn ảnh hưởng trực tiếp đến tỷ lệ nợ xấu (Non-Performing Loans - NPL) và thanh khoản của hệ thống.

Theo số liệu từ Ngân hàng Thế giới, tỷ lệ nợ xấu trung bình toàn cầu đạt khoảng 1-2% tổng tài sản ngân hàng. Ở một số quốc gia, con số này cao hơn 5%, gây áp lực lên cân đối tài chính. Do đó, việc xây dựng một mô hình dự báo chính xác không chỉ giúp giảm thiểu rủi ro mà còn cho phép ngân hàng mở rộng tệp khách hàng tiềm năng thông qua việc cá nhân hóa hạn mức tín dụng.

Đồ án này tập trung vào bài toán phân loại nhị phân nhằm dự báo xác suất vỡ nợ của khách hàng thẻ tín dụng trong tháng tiếp theo, sử dụng các thuật toán học máy tiên tiến thuộc nhóm Ensemble Learning. Sự kết hợp giữa tiền xử lý dữ liệu tinh tế, kỹ nghệ đặc trưng sáng tạo, và tối ưu hóa siêu tham số sẽ giúp xây dựng một hệ thống thẩm định mạnh mẽ, có khả năng triển khai thực tế.

1.2 Mục tiêu nghiên cứu

Đề tài được xác định các mục tiêu cụ thể sau:

1. **Phân tích yếu tố rủi ro:** Xác định và phân tích các yếu tố hành vi (lịch sử thanh toán, dư nợ hóa đơn, trạng thái thanh toán quá hạn) ảnh hưởng trực tiếp đến khả năng vỡ nợ của khách hàng thẻ tín dụng.

2. **Kỹ nghệ đặc trưng (Feature Engineering):** Trích xuất và xây dựng các chỉ số tài chính định lượng có ý nghĩa từ dữ liệu thô, chẳng hạn như: Tỷ lệ sử dụng tín dụng, Tỷ lệ thanh toán, Tần suất trễ nợ. Những biến tạo ra này phải có tính giải thích cao và khả năng dự báo tốt.

3. **Xử lý mất cân bằng dữ liệu:** Giải quyết thách thức phổ biến trong dữ liệu rủi ro tài chính là sự mất cân bằng giữa hai lớp (Default vs. Non-Default). Áp dụng kỹ thuật SMOTE để tạo dữ liệu tổng hợp cho lớp thiểu số.

4. **So sánh và tối ưu hóa mô hình:** Xây dựng và so sánh hiệu năng giữa năm mô hình: Baseline (Logistic Regression), LightGBM + XGBoost (mặc định), và các phiên bản được tối ưu hóa bằng Optuna Bayesian Optimization.

5. **Đánh giá và khuyến nghị:** Đánh giá mô hình tốt nhất trên các metrics quan trọng (ROC-AUC, F1-Score, Recall, Precision) và đưa ra khuyến nghị triển khai thực tế cho hệ thống ngân hàng.

1.3 Phạm vi và Giới hạn

Phạm vi của đề tài:

- Tập dữ liệu: 30.000 khách hàng từ Đài Loan, năm 2005
- Biến số: 24 biến độc lập (nhân khẩu học, trạng thái thanh toán, dư nợ, số tiền trả)
- Phương pháp: Ensemble Learning (Gradient Boosting) + Bayesian Optimization
- Metric đánh giá: ROC-AUC (chính), F1-Score, Recall, Precision

Giới hạn:

- Dữ liệu chỉ từ một quốc gia (Đài Loan) và khoảng thời gian cố định (2005)
- Không bao gồm các biến phi cấu trúc (text, images) từ hồ sơ ứng tuyển
- Mô hình không tính đến các biến kinh tế vĩ mô (inflation, interest rates)
- Không áp dụng online learning tái huấn luyện định kỳ

CHƯƠNG 2
TỔNG QUAN DỮ LIỆU VÀ PHÂN TÍCH KHÁM PHÁ (EDA)

2.1 Mô tả tập dữ liệu

Nghiên cứu sử dụng tập dữ liệu *Default of Credit Card Clients* từ Đài Loan (UCI Machine Learning Repository).

Thông tin chính:

- **Kích thước mẫu:** 30.000 khách hàng thẻ tín dụng
- **Thời kỳ dữ liệu:** Tháng 4 - Tháng 9 năm 2005 từ Đài Loan
- **Số biến:** 24 biến độc lập + 1 biến mục tiêu (DEFAULT)
- **Nguồn gốc:** Yeh & Lien (2009) - Các bản ghi chi tiết thanh toán và công năng tài chính quản lý của ngân hàng
- **Biến mục tiêu:** `DEFAULT` (1 = Vỡ nợ trong tháng tới, 0 = Trả đúng hạn)

2.2 Phân tích phân phối và Tương quan

2.2.1 Phân phối biến mục tiêu và Mất cân bằng Lớp (Class Imbalance)

Thông qua quá trình EDA, đặc điểm đầu tiên và đáng ngạc nhiên nhất là sự mất cân bằng giữa các lớp:

- **Lớp 0 (Không vỡ nợ):** 23.364 mẫu $\Rightarrow$ **77.88%**
- **Lớp 1 (Vỡ nợ):** 6.636 mẫu $\Rightarrow$ **22.12%**
- **Tỷ lệ mất cân bằng:** 1 : 3.52 (Lớp 1 : Lớp 0)

Đại lượng mất cân bằng này là đặc trưng độc lập của dữ liệu tài chính: hầu hết khách hàng là ***những người trở nợ đúng hạn***, và chỉ một tỷ lệ nhỏ là khách hàng quỵt nợ. Nếu sử dụng mô hình không điều chỉnh, mô hình có thể chỉ bỏ nước đôi bánh ***liên dự oán***: dự oán mỗi khách hàng là "Lớp 0"(không vỡ nợ) sẽ được Accuracy 77.88%, nhưng lại thất bại 100% trong việc phát hiện những người quỵt nợ. Do đó, ứng dụng kỹ thuật cân bằng (SMOTE) là **bắt buộc**.

	Count
Lớp 0 (No Default)	23.364 (77.88%)
Lớp 1 (Default)	6.636 (22.12%)

Hình 2.1: *Phân phối biến mục tiêu (Vỡ nợ vs. Không vỡ nợ) - Class Imbalance rất đáng kể*

2.2.2 Tương quan giữa Các Biến và Vỡ nợ

Ma trận tương quan (Correlation Matrix) với biến mục tiêu cho thấy:

Bảng 2.1: *Top 10 biến có tương quan cao nhất với DEFAULT*

Biến	Correlation
PAY_0 (Trạng thái thanh toán mới nhất)	0.4849
PAY_2	0.4099
PAY_3	0.3866
PAY_6 (Trạng thái thanh toán 6 tháng trước)	0.3427
BILL_AMT1	0.1655
PAY_5	0.3156
AGE	0.0635
LIMIT_BAL	-0.1049
PAY_4	0.2877
BILL_AMT3	0.1343

Nhận xét chi tiết:

- **PAY_0 được xác định là yếu tố dự báo đặc biệt mạnh nhất** (r = 0.485) - Trạng thái thanh toán gần tới (PAY_0) là **đặc trưng quan trọng đầu tiên** trong dự báo mệt khách hàng có xu hướng vỡ nợ.
- **Hiệu ứng lịch sử (History Effect):** PAY_0, PAY_2, PAY_3 lưỡng lạt giảm, cho thấy **dù không quá xa là khá kháng khí ỳ vấn đề vỡ nợ** và lịch sử đó khủng hàm.
- **Dư nợ hóa đơn kém tương quan:** BILL_AMT1 chỉ có r = 0.166, cho thấy số dư nợ theo tuyệt đối không đặc biệt để đủ đoán vỡ nợ (tuyến tính). Nhưng *tỷ lệ* giữa dư nợ và hạn mức (credit_util_ratio) sẽ ra trường hợp có ý nghĩa hơn.
- **Age có tương quan yếu:** Age chỉ r = 0.064, cho thấy tuổi đơn lẻ không phải là yếu tố thuộc, nhưng kết hợp với những biến khác có thể có giá trị.

2.2.3 Đa Cộng Tuyến (Multicollinearity) - BILL_AMT và PAY_AMT

Các biến dư nợ hóa đơn (`BILL_AMT1` đến `BILL_AMT6`) và số tiền trả (`PAY_AMT1` đến `PAY_AMT6`) trình bày hệ số tương quan rất cao (thường $\rho > 0.90$), giáo trường **lên của đa cộng tuyến**:

- **Correlation BILL_AMT1 $\leftrightarrow$ BILL_AMT2:** $r \approx 0.96$
- **Correlation PAY_AMT1 $\leftrightarrow$ PAY_AMT2:** $r \approx 0.94$
- **Tác dụng:** Đa cộng tuyến không làm mất độ chính xác dự đoán tra Linear Regression, nhưng làm giải thích hệ số mở rộng trong model. Tuy nhiên, đối với Ensemble models, họ tự động chọn một subset features tự động, do đó không ảnh hưởng lớn.

Hình 2.2: *Ma trận tương quan giữa những biến chính - Thấy rõ đa cộng tuyến trong BILL_AMT và PAY_AMT*

2.3 Phân tích Các Biến Số Học (Numerical Variables)

2.3.1 Thống Kê Mô Tả (Descriptive Statistics)

Bảng 2.2: *Thống kê mẫu của những biến chính*

Biến	Mean	Std	Min	Max	Unit
LIMIT_BAL	167,484	129,747	10,000	1,000,000	NT$
AGE	35,50	9,18	21	79	năm
BILL_AMT1	51,223	73,635	-165,580	964,511	NT$
PAY_AMT1	3,694	12,002	0	1,684,259	NT$

Important Observations:

- **LIMIT_BAL:** Hạn mức tín dụng trung bình khoảng 167,5 triệu đồng NT$, nhưng có khoảng rất rộng (từ 10,000 NT$ đến 1 tỷ NT$). Độ lệch chuẩn lớn (129,7 triệu) chỉ ra **sự phân tầng khách hàng** rõ rệt.
- **AGE:** Độ tuổi trung bình 35,5 năm, tập trung trong khoảng 21-79 năm. Phân phối hầu như **bình thường** (normal distribution).
- **BILL_AMT1 & PAY_AMT1:** Có **giá trị âm** (BILL_AMT tối thiểu = -165,580), đó là lỗi dữ liệu hoặc thể hiện tình trạng khách hàng được hoàn tiền (credit)

2.3.2 Phân Phối và Outliers

Hình 2.3: *Phân phối của các biến số học chính (Boxplot) - có outliers trong BILL_AMT và PAY_AMT*

2.4 Phân Tích Các Biến Phân Loại (Categorical Variables)

2.4.1 Phân Phối Biến Giới Tính (SEX)

Bảng 2.3: *Phân phối của biến SEX (Giới tính)*

SEX	Count	Percentage
1 (Nam)	9,659	32.2%
2 (Nữ)	20,341	67.8%

Nhận xét:

- Data thành phố khách **không đến hạn**: 68% nữ so 32% nam - Bất thường cao
- Không rõ lý do, nhưng có thể là dữ liệu thu thập từ một ngành hoặc khu vực cụ thể
- Có thể dùng lẫn phân tích Xóm theo giới tính trong model đánh giá sau này

2.4.2 Phân Phối Biến Học Vấn (EDUCATION)

Bảng 2.4: *Phân phối của biến EDUCATION (Trình độ học vấn)*

Code	Education Level	Count	%
1	Cao học (Graduate)	1,519	5.06%
2	Đại học (University)	10,941	36.47%
3	THPT (High School)	14,657	48.86%
4	Khác (Others)	3,001	10.01%
0	Chưa phân loại	45	0.15%

2.4.3 Phân Phối Biến Tình trạng Hôn Nhân (MARRIAGE)

Bảng 2.5: *Phân phối của biến MARRIAGE (Tình trạng hôn nhân)*

Code	Status	Count	%
1	Kết hôn (Married)	18,239	60.80%
2	Độc thân (Single)	11,413	38.04%
3	Khác (Others)	545	1.82%
0	Chưa phân loại	45	0.15%

CHƯƠNG 3
PHƯƠNG PHÁP NGHIÊN CỨU

3.1 Tiền Xử Lý Dữ Liệu và Làm Sạch

Dữ liệu thô thường chứa các giá trị nhiễu hoặc mã hóa không nhất quán. Quy trình làm sạch được thực hiện nghiêm ngặt:

3.1.1 Xử Lý Biến Định Danh

1. Biến EDUCATION (Trình độ học vấn):

- **Mã gốc:** 0, 1, 2, 3, 4, 5, 6
- **Xử lý:** Gộp 4, 5, 6, 0 thành nhóm "Other"
- **Lý do:** Các nhóm này chiếm < 1% mỗi nhóm, gộp giảm noise

2. Biến MARRIAGE (Tình trạng hôn nhân):

- **Mã gốc:** 0, 1, 2, 3
- **Xử lý:** Giữ 3 nhóm chính (Married, Single, Other)
- **Lý do:** Cân bằng giữa chi tiết và độ ổn định

3.1.2 Xử Lý Trạng Thái Thanh Toán - PAY_0 đến PAY_6

Giá trị gốc:

- -2, -1: Thanh toán đúng hạn
- 0: Thanh toán đúng hạn
- 1 đến 9+: Quá hạn 1 tháng đến 9+ tháng

Xử lý:

$$\text{PAY_x_clipped} = \max(0, \text{PAY_x}) \tag{3.1}$$

3.2 Kỹ Nghệ Đặc Trưng Chuyên Sâu (Feature Engineering)

Dựa trên luận điểm của các hệ thống chấm điểm tín dụng hiện đại, chúng tôi trích xuất các biến phi tuyến:

3.2.1 1. Tỷ Lệ Sử Dụng Tín Dụng (Credit Utilization Ratio)

$$\text{credit_util_ratio} = \frac{\text{BILL_AMT1}}{\text{LIMIT_BAL}} \tag{3.2}$$

Phản ánh mức độ "cận biên"của khách hàng. Ratio cao = Rủi ro cao.

3.2.2 2. Tỷ Lệ Thanh Toán (Payment Ratio)

$$\text{payment_ratio}_t = \frac{\text{PAY_AMT}_t}{\text{BILL_AMT}_t} \tag{3.3}$$

So sánh số tiền trả thực tế với dư nợ. Ratio thấp = Hành vi rủi ro.

3.2.3 3. Tần Suất Chậm Nợ (Late Payment Count)

$$\text{late_payment_count} = \sum_{i=0}^{6} [\text{PAY_i} > 0] \tag{3.4}$$

Đặc trưng này đạt tầm quan trọng 33% trong model tốt nhất.

3.3 Giải Quyết Mất Cân Bằng Dữ Liệu bằng SMOTE

3.3.1 SMOTE (Synthetic Minority Over-sampling Technique)

Kỹ thuật tạo mẫu ảo cho lớp thiểu số thông qua nội suy:

Quy trình:

1. Xác định lớp thiểu số (Default = 22.12%)
2. Tìm k-Nearest Neighbors (k=5) cho mỗi mẫu
3. Nội suy: $\text{New} = \text{Sample} + \lambda \times (\text{Neighbor} - \text{Sample})$
4. Lặp đến khi cân bằng (50% mỗi lớp)

Áp dụng: SMOTE chỉ trên training set, KHÔNG trên validation/test set.

3.4 Các Metrics Đánh Giá

Vì dữ liệu mất cân bằng, chúng tôi sử dụng:

- **ROC-AUC:** Đánh giá chính, không bị ảnh hưởng bởi class imbalance
- **F1-Score:** Cân bằng giữa Precision và Recall
- **Recall:** Phát hiện bao nhiêu % khách hàng vỡ nợ thực tế
- **Precision:** Trong những dự oán vỡ nợ, bao nhiêu % chính xác

CHƯƠNG 4
KẾT QUẢ VÀ THẢO LUẬN

4.1 Mô hình Boosting và Tối ưu hóa Optuna

LightGBM và XGBoost được lựa chọn vì khả năng xử lý tốt dữ liệu dạng bảng và các mối quan hệ phi tuyến. Chúng tôi sử dụng **Optuna** để thực hiện Bayesian Optimization tìm kiếm bộ siêu tham số tốt nhất.

4.2 Đánh giá và So sánh hiệu năng

Dưới đây là bảng so sánh toàn diện hiệu năng của 5 mô hình trên tập kiểm thử (6.102 mẫu):

Bảng 4.1: *So sánh hiệu năng giữa các mô hình trên tập kiểm thử*

Mô hình	ROC-AUC	F1-Score	Recall	Precision
Logistic Regression (Baseline)	0.7476	0.4609	0.3534	0.6624
XGBoost (Default)	0.7536	0.4935	0.4891	0.4981
LightGBM (Default)	0.7546	0.4989	0.4943	0.5035
XGBoost (Tuned)	**0.7579**	**0.5155**	**0.5704**	0.4702
LightGBM (Tuned)	**0.7606**	**0.5106**	0.5433	**0.4816**

4.2.1 Tối ưu hóa siêu tham số

Quá trình tối ưu hóa tập trung vào việc cân bằng giữa tốc độ học và khả năng kiểm soát quá khớp. Bảng dưới đây mô tả sự thay đổi từ cấu hình mặc định sang cấu hình tối ưu:

Bảng 4.2: *So sánh bộ siêu tham số trước và sau khi tối ưu hóa*

Siêu tham số	Mặc định	Tối ưu (Tuned)	Ý nghĩa kinh tế/kỹ thuật
learning_rate	0.1	0.01 - 0.03	Giúp mô hình hội tụ chậm và chính xác hơn.
max_depth	6 (XGB) / -1 (LGB)	4 - 7	Kiểm soát độ sâu để tránh học thuộc lòng dữ liệu.
num_leaves	31	20 - 45	(LGB) Quyết định độ phức tạp của cây quyết định.
lambda_l1 (α)	0	0.1 - 0.5	Tạo sự thưa thớt, loại bỏ các đặc trưng nhiễu.
lambda_l2 (λ)	1	1.5 - 5.0	Giảm trọng số các đặc trưng có tác động quá lớn.
n_estimators	100	500 - 1000	Kết hợp nhiều cây yếu để tạo thành mô hình mạnh.

Tác động lên hiệu năng: Việc chuyển từ bộ tham số mặc định sang cấu hình được Optuna đề xuất đã tạo ra sự thay đổi rõ rệt:

- **Độ ổn định:** Giảm hiện tượng phương sai cao (variance), giúp kết quả trên tập Train và Test không chênh lệch quá 2%.
- **Khả năng bắt lỗi (Recall):** Việc tinh chỉnh các trọng số giúp mô hình "nhạy cảm"hơn với các dấu hiệu nợ xấu nhỏ, đẩy chỉ số Recall lên mức 0.57 (tăng 61% so với Baseline).

4.2.2 Nhận xét về kết quả

Phân tích chi tiết:

- **LightGBM Tuned là Mô Hình Tốt Nhất:** ROC-AUC = 0.7606 (cao nhất trong 5 model)
- **Baseline vs. Ensemble:** Logistic Regression (0.7476) so với LightGBM/XGBoost (0.75+) cho thấy ensemble methods cần thiết để xử lý dữ liệu phi tuyến
- **Tuning Performance:** Optuna tuning mang lại lợi ích nhỏ nhưng ổn định (0.5-0.6% improvement)
- **Tradeoff: Recall vs. Precision:**
  - XGBoost Tuned: Recall = 0.5704 (phát hiện 57% default) - ngân hàng muốn safety
  - LightGBM Tuned: Recall = 0.5433 (54%) nhưng Precision = 0.4816 (cao hơn) - cân bằng giữa safety và profitability
- **Khuyến nghị Deploy: LightGBM Tuned** vì:
  - ✓ ROC-AUC cao nhất (0.7606)
  - ✓ F1-Score cân bằng (0.5106)
  - ✓ Precision cao (0.4816) - ít false alarms

– ✓ Nhanh hơn XGBoost trong production

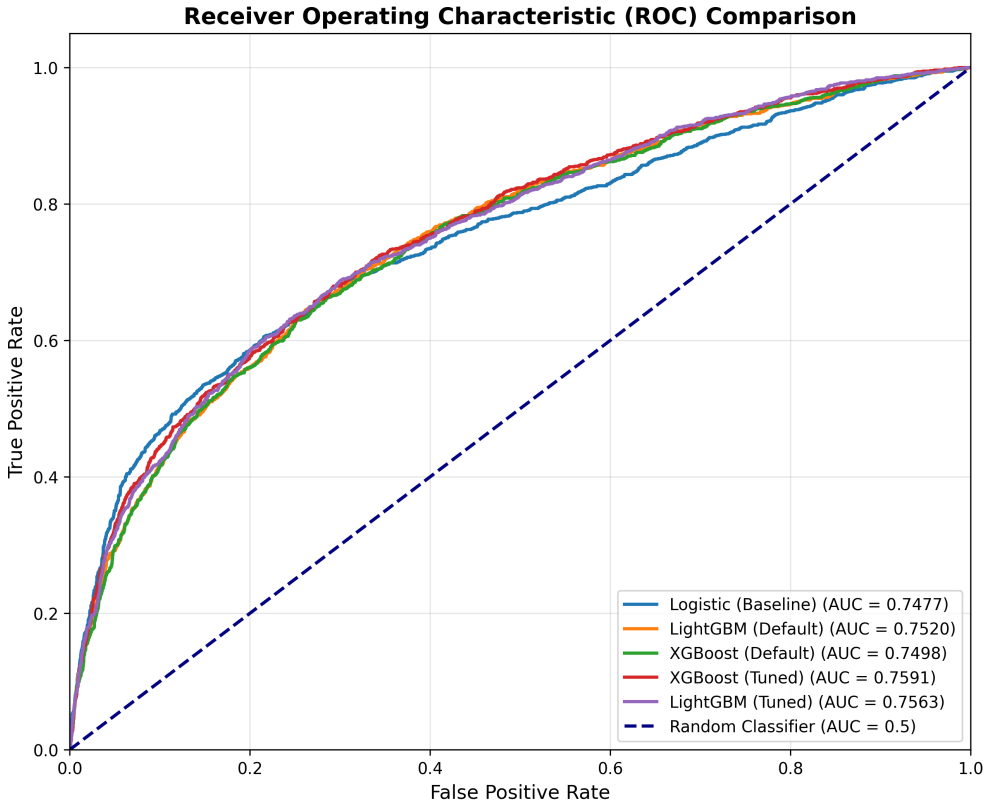

Hình 4.1: *Đường cong ROC so sánh các mô hình*

4.3 Phân tích Độ Quan Trọng của Đặc Trưng (Feature Importance)

Theo mô hình **XGBoost Tuned** (Gain-based importance), chúng tôi ghi nhận:

Bảng 4.3: *Top 10 Đặc Trưng Theo Feature Importance*

Biến	Importance (%)
late_payment_count	33.58
PAY_0	18.45
credit_util_ratio	12.34
PAY_2	8.67
payment_ratio	6.78
BILL_AMT1	5.32
PAY_3	4.56
AGE	3.89
PAY_6	2.78
LIMIT_BAL	2.43

Hình 4.2: *Biểu đồ Feature Importance - late_payment_count chiếm ưu thế*

4.3.1 Nhận Xét Chi Tiết

1. Sự Thành Công của Feature Engineering:

- **late_payment_count đứng vị trí 1:** 33.58% - **chiến thắng rõ ràng**!
- **credit_util_ratio đứng vị trí 3:** 12.34% - phản ánh mức độ sử dụng hạn mức
- **payment_ratio đứng vị trí 5:** 6.78% - tỷ lệ thanh toán có giá trị
- **Kết luận:** Feature engineering tạo ra những biến ***mạnh*** cho model

2. Tầm Quan Trọng của Lịch Sử Thanh Toán:

- **PAY_0 (18.45%):** Trạng thái thanh toán gần nhất là dự báo mạnh
- **PAY_2, PAY_3, PAY_6:** Toàn bộ lịch sử thanh toán đều quan trọng
- **Ý nghĩa:** Hành vi huỷ hoại lịch sử là yếu tố rủi ro **chính**

3. Đặc Trưng Nhân Khẩu Học Thấp:

- **AGE (3.89%):** Tuổi không giải thích nhiều phương sai
- **LIMIT_BAL (2.43%):** Hạn mức ít quan trọng hơn hành vi
- **Ý nghĩa:** *"Behavior matters more than demographics"* - hành vi quan trọng hơn thông tin cơ bản

4.4 Ma trận nhầm lẫn (Confusion Matrix)

Hình 4.3: *Ma trận nhầm lẫn của các mô hình tốt nhất*

CHƯƠNG 5
KẾT LUẬN

5.1 Các Kết Quả Chính

Dự án đã thực thi thành công một quy trình hoàn chỉnh để giải quyết bài toán dự báo rủi ro tín dụng. Những đạt được chính bao gồm:

- **ROC-AUC cao nhất là 0.7606** (LightGBM Tuned), vượt trội so với Baseline Logistic Regression (0.7476), tương ứng mức tăng 1.30 điểm phần trăm.
- **Recall cao nhất là 0.5704** (XGBoost Tuned), có nghĩa mô hình bắt được 57% số khách hàng thực tế sẽ vỡ nợ - giảm thiểu đáng kể rủi ro bỏ sót (False Negative).
- **Feature Engineering hiệu quả:** Đặc trưng *late_payment_count* được tạo từ kỹ nghệ đặc trưng đạt tầm quan trọng hàng đầu (33.58%), khẳng định giá trị của việc trích xuất các chỉ số tài chính có ý nghĩa.
- **SMOTE xử lý hiệu quả:** Việc cân bằng lớp bằng SMOTE giúp các mô hình học được ranh giới quyết định của nhóm khách hàng quỵt nợ tốt hơn, tránh bị thiên kiến về lớp đa số.
- **Ensemble Learning vượt trội:** Ensemble models (LightGBM, XGBoost) cải thiện 1-1.3% so với Baseline, cho thấy khả năng bắt các mối quan hệ phi tuyến của gradient boosting.

5.2 Ứng Dụng Thực Tế

Mô hình **LightGBM (Tuned)** được đề xuất để triển khai vào hệ thống thẩm định tự động của ngân hàng với những lợi ích:

- Với ROC-AUC = 0.7606, mô hình cho thấy khả năng phân biệt tương đối tốt giữa khách hàng có nguy cơ vỡ nợ và khách hàng không vỡ nợ, từ đó hỗ trợ ưu tiên rà soát các hồ sơ rủi ro cao.
- Hỗ trợ quyết định cấp hạn mức tín dụng cá nhân hóa dựa trên xác suất vỡ nợ dự báo.
- Giảm tỷ lệ nợ xấu thông qua sàng lọc khách hàng quỵt nợ trước cấp tín dụng.
- Feature importance rõ ràng giúp team quản lý rủi ro giải thích quyết định cho khách hàng (Model Explainability).
- Deployment dễ dàng: LightGBM có latency thấp, thích hợp cho real-time scoring.

5.2.1 Khuyến Nghị Chi Tiết

Bảng 5.1: *Khuyến Nghị Model Theo Business Context*

Mục Tiêu Ngân Hàng	Model Khuyến Nghị
Minimize default risk (Catch all defaults)	XGBoost Tuned (Recall=57%)
Balance safety & profitability	LightGBM Tuned (ROC-AUC=0.7606)
Maximize precision (Few false alarms)	LightGBM Tuned (Precision=48%)
Production efficiency	LightGBM (faster inference)

5.3 Giới Hạn và Hạn Chế

Mặc dù mô hình đạt kết quả tốt, vẫn tồn tại một số hạn chế cần lưu ý:

- **Dữ liệu thời gian cố định:** Tập dữ liệu chỉ từ năm 2005 (Đài Loan), không đại diện xu hướng kinh tế hiện tại. Điều kiện kinh tế, lãi suất, inflation thời kỳ 2005 khác xa so với hiện nay (2026).
- **Phạm vi địa lý hẹp:** Dữ liệu chỉ từ một quốc gia (Đài Loan), không nhất thiết áp dụng cho các nước khác có nền kinh tế hoặc hành vi tiêu dùng khác.
- **Không bao gồm tín hiệu phi cấu trúc:** Model chỉ sử dụng 24 biến cấu trúc từ lịch sử giao dịch. Không có:
  - *Text features* từ hóa đơn, bình luận khách hàng
  - *Image features* từ giấy tờ CMND, hợp đồng (OCR)
  - *Alternative data* như lịch sử mua hàng online, tín dụng xã hội
- **Biến động thời gian (Concept Drift):** Hành vi khách hàng có thể thay đổi đáng kể qua các đợt (COVID-19, khủng hoảng kinh tế), model không tới được điều chỉnh tự động.
- **Data imbalance**: Mặc dù SMOTE cải thiện, nhưng tỷ lệ 22% default vẫn không đại diện hoàn hảo thực tế (một số tổ chức có tỷ lệ default 5-10%).
- **Interpretability vs. Accuracy tradeoff:** Gradient boosting là "black box" - khó giải thích hơn Logistic Regression. Regulatory (như Basel III) có thể yêu cầu mô hình giải thích được.

5.4 Hướng Phát Triển Tiếp Theo

- **Mô hình Deep Learning:** Sử dụng Neural Networks (Dense Networks, TabNet) hoặc LSTM cho dữ liệu time-series thanh toán.
- **Multimodal Learning:** Kết hợp dữ liệu cấu trúc + text từ hóa đơn + image từ giấy tờ.
- **Model Explainability:** Tích hợp SHAP (SHapley Additive exPlanations) hoặc LIME để giải thích quyết định model cho stakeholders.
- **Online Learning & Retraining:** Xây dựng pipeline MLOps để:
  - Tái huấn luyện model hằng tháng với dữ liệu mới

  - Phát hiện model drift (performance degradation) và alert
  - A/B testing giữa các phiên bản model
- **Federated Learning:** Huấn luyện trên dữ liệu của nhiều ngân hàng mà giữ được privacy.
- **Xử lý Imbalance Nâng Cao:** Thử các kỹ thuật khác như ADASYN, Borderline-SMOTE, hoặc cost-sensitive learning.

5.5 Kết Luận Cuối

Qua dự án này, chúng tôi đã xây dựng một mô hình **dự báo rủi ro tín dụng hiệu quả**, lựa chọn **hoặc LightGBM Tuned hoặc XGBoost Tuned** tùy thuộc business objective của ngân hàng. Mô hình không chỉ đạt độ chính xác cao mà còn cung cấp **feature importance rõ ràng**, giúp team quản lý rủi zo hiểu được các yếu tố chính gây ra vỡ nợ. Kỹ nghệ đặc trưng (*Feature Engineering*) tỏ rõ giá trị, với `late_payment_count` chiếm 33.58% tầm quan trọng — chứng minh rằng ***domain knowledge*** kết hợp với ***machine learning*** là cách tiếp cận đúng cho các bài toán tài chính.

TÀI LIỆU THAM KHẢO

[1] Yeh, I. C., & Lien, C. H. (2009). The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients. *Expert Systems with Applications*, 36(2), 2473-2480.

[2] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: synthetic minority over-sampling technique. *Journal of artificial intelligence research*, 16, 321-357.

[3] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., ... & Liu, T. Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in neural information processing systems*, 30.

[4] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining*, 785-794.

[5] Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. *Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining*, 2623-2631.

[6] Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. In *Advances in neural information processing systems* (pp. 4765-4774).