**ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH**
**TRƯỜNG ĐẠI HỌC BÁCH KHOA**
**KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH**

# BÀI TẬP LỚN

## Lập trình cho Trí tuệ nhân tạo và Khoa học dữ liệu

(Mã học phần: CO3135)

---

# XÂY DỰNG HỆ THỐNG DỰ ĐOÁN RỦI RO TÍN DỤNG DỰA TRÊN DỮ LIỆU THẺ TÍN DỤNG

---

**GVHD:** Thầy Huỳnh Văn Thống

**SVTH:** Phạm Thanh Phong **2212564**
Hoàng Phương Bình **2210305**
Võ Lê Anh Nghĩa **2252530**
Vũ Xuân Chính **2210392**

Thành phố Hồ Chí Minh, tháng 04 năm 2026

# BẢNG PHÂN CÔNG NHIỆM VỤ

| STT | MSSV | Họ và Tên | Nhiệm vụ phân công | Mức độ |
|---|---|---|---|---|
| 1 | 2212564 | Phạm Thanh Phong | **Báo cáo:** Viết Báo Cáo LATEX<br>**Kỹ thuật:** Data Cleaning, Feature Engineering (chung), Evaluation (Đánh giá mô hình) | 100% |
| 2 | 2210305 | Hoàng Phương Bình | **Báo cáo:** Viết Báo Cáo LATEX<br>**Kỹ thuật:** Khởi tạo & Load Data, EDA (Khám phá dữ liệu), Explainability (SHAP) | 100% |
| 3 | 2252530 | Võ Lê Anh Nghĩa | **Báo cáo:** Viết Báo Cáo LATEX & 5<br>**Kỹ thuật:** Khảo sát tài liệu, Data Split & Encoding, Chạy Baseline Models | 100% |
| 4 | 2210392 | Vũ Xuân Chính | **Báo cáo:** Viết Báo Cáo LATEX<br>**Kỹ thuật:** Feature Engineering (chung), Xử lý mất cân bằng (SMOTE), Advanced Models, Hyper-parameter Tuning (Optuna) | 100% |

# MỤC LỤC

**1 GIỚI THIỆU** **1**
1.1 Lý do thực hiện đề tài . . . . . 1
1.2 Mục tiêu nghiên cứu . . . . . 1
1.3 Phạm vi và Giới hạn . . . . . 2

**2 TỔNG QUAN DỮ LIỆU VÀ PHÂN TÍCH KHÁM PHÁ (EDA)** **3**
2.1 Mô tả tập dữ liệu . . . . . 3
2.2 Phân tích phân phối và Tương quan . . . . . 3
2.2.1 Phân phối biến mục tiêu và Mất cân bằng Lớp (Class Imbalance) . . . . . 3
2.2.2 Tương quan giữa Các Biến và Vỡ nợ . . . . . 4
2.2.3 Đa Cộng Tuyến (Multicollinearity) - BILL_AMT và PAY_AMT . . . . . 4
2.3 Phân tích Các Biến Số Học (Numerical Variables) . . . . . 5
2.3.1 Thống Kê Mô Tả (Descriptive Statistics) . . . . . 5
2.3.2 Phân Phối và Outliers . . . . . 5
2.4 Phân Tích Các Biến Phân Loại (Categorical Variables) . . . . . 5
2.4.1 Phân Phối Biến Giới Tính (SEX) . . . . . 5
2.4.2 Phân Phối Biến Học Vấn (EDUCATION) . . . . . 6
2.4.3 Phân Phối Biến Tình trạng Hôn Nhân (MARRIAGE) . . . . . 6

**3 PHƯƠNG PHÁP NGHIÊN CỨU** **7**
3.1 Tiền Xử Lý Dữ Liệu và Làm Sạch . . . . . 7
3.1.1 Xử lý các biến phân loại (Categorical Features) . . . . . 7
3.1.2 Chuẩn hóa các biến trạng thái thanh toán (`PAY_0` đến `PAY_6`) . . . . . 7
3.2 Kỹ Nghệ Đặc Trưng (Feature Engineering) . . . . . 7
3.2.1 Tỷ Lệ Sử Dụng Hạn Mức Tín Dụng (Credit Utilization Ratio) . . . . . 8
3.2.2 Tỷ Lệ Thanh Toán (Payment Ratio) . . . . . 8
3.2.3 Tần Suất Chậm Thanh Toán (Late Payment Count) . . . . . 8
3.3 Xử lý Mất Cân Bằng Dữ Liệu - Kỹ Thuật SMOTE . . . . . 8
3.4 Quy trình chuyển đổi dữ liệu và Chiến lược mô hình hóa (Modeling Strategy) . . . 9
3.4.1 Đường ống chuyển đổi dữ liệu (Data Transformation Pipeline) . . . . . 9
3.4.2 Mô hình cơ sở (Baseline Model) . . . . . 10
3.4.3 Nhóm mô hình học dựa trên cây (Tree-Based Models) . . . . . 10

3.4.4 Tối ưu hóa siêu tham số với Optuna (Hyperparameter Tuning) . . . . . 10
3.5 Đánh giá Hiệu năng và Khả năng Giải thích của Mô hình (Metrics & Explainable AI) . . . . . 11
3.5.1 Các độ đo đánh giá hiệu năng (Performance Metrics) . . . . . 11
3.5.2 Khả năng giải thích mô hình với SHAP (Explainable AI - XAI) . . . . . 11

**4 KẾT QUẢ VÀ THẢO LUẬN 13**
4.1 Mô hình Boosting và Tối ưu hóa Optuna . . . . . 13
4.2 Đánh giá và So sánh hiệu năng . . . . . 13
4.2.1 Tối ưu hóa siêu tham số . . . . . 13
4.2.2 Nhận xét về kết quả . . . . . 14
4.3 Phân tích Độ Quan Trọng của Đặc Trưng (Feature Importance) . . . . . 15
4.3.1 Nhận Xét Chi Tiết . . . . . 16
4.4 Ma trận nhầm lẫn (Confusion Matrix) . . . . . 16

**5 KẾT LUẬN 17**
5.1 Các Kết Quả Chính . . . . . 17
5.2 Ứng Dụng Thực Tế . . . . . 17
5.2.1 Khuyến Nghị Chi Tiết . . . . . 18
5.3 Giới Hạn và Hạn Chế . . . . . 18
5.4 Hướng Phát Triển Tiếp Theo . . . . . 18
5.5 Kết Luận Cuối . . . . . 19

**TÀI LIỆU THAM KHẢO 20**

# DANH SÁCH HÌNH VẼ

Hình 2.1 Phân phối biến mục tiêu (Vỡ nợ vs. Không vỡ nợ) - Class Imbalance rất đáng kể 3
Hình 2.2 Ma trận tương quan giữa những biến chính - Thấy rõ đa cộng tuyến trong BILL_AMT và PAY_AMT . . . . . 5
Hình 2.3 Phân phối của các biến số học chính (Boxplot) - có outliers trong BILL_AMT và PAY_AMT . . . . . 5

Hình 4.1 Đường cong ROC so sánh các mô hình . . . . . 15
Hình 4.2 Biểu đồ Feature Importance - late_payment_count chiếm ưu thế . . . . . 16
Hình 4.3 Ma trận nhầm lẫn của các mô hình tốt nhất . . . . . 16

# DANH SÁCH BẢNG

Bảng 2.1 Top 10 biến có tương quan cao nhất với DEFAULT . . . . . 4
Bảng 2.2 Thống kê mẫu của những biến chính . . . . . 5
Bảng 2.3 Phân phối của biến SEX (Giới tính) . . . . . 5
Bảng 2.4 Phân phối của biến EDUCATION (Trình độ học vấn) . . . . . 6
Bảng 2.5 Phân phối của biến MARRIAGE (Tình trạng hôn nhân) . . . . . 6

Bảng 4.1 So sánh hiệu năng giữa các mô hình trên tập kiểm thử . . . . . 13
Bảng 4.2 So sánh bộ siêu tham số trước và sau khi tối ưu hóa . . . . . 14
Bảng 4.3 Top 10 Đặc Trưng Theo Feature Importance . . . . . 16

Bảng 5.1 Khuyến Nghị Model Theo Business Context . . . . . 18

# CHƯƠNG 1
# GIỚI THIỆU

## 1.1 Lý do thực hiện đề tài

Trong bối cảnh nền kinh tế số phát triển mạnh mẽ, các cơ sở tài chính và ngân hàng đang chuyển dịch từ phương thức thẩm định truyền thống sang hệ thống thẩm định tự động dựa trên dữ liệu lớn (Big Data). Rủi ro tín dụng, cụ thể là khả năng khách hàng không thể hoàn trả nợ đúng hạn, là yếu tố sống còn ảnh hưởng trực tiếp đến tỷ lệ nợ xấu (Non-Performing Loans - NPL) và thanh khoản của hệ thống.

Theo số liệu từ Ngân hàng Thế giới, tỷ lệ nợ xấu trung bình toàn cầu đạt khoảng 1-2% tổng tài sản ngân hàng. Ở một số quốc gia, con số này cao hơn 5%, gây áp lực lên cân đối tài chính. Do đó, việc xây dựng một mô hình dự báo chính xác không chỉ giúp giảm thiểu rủi ro mà còn cho phép ngân hàng mở rộng tệp khách hàng tiềm năng thông qua việc cá nhân hóa hạn mức tín dụng.

Đồ án này tập trung vào bài toán phân loại nhị phân nhằm dự báo xác suất vỡ nợ của khách hàng thẻ tín dụng trong tháng tiếp theo, sử dụng các thuật toán học máy tiên tiến thuộc nhóm Ensemble Learning. Sự kết hợp giữa tiền xử lý dữ liệu tinh tế, kỹ nghệ đặc trưng sáng tạo, và tối ưu hóa siêu tham số sẽ giúp xây dựng một hệ thống thẩm định mạnh mẽ, có khả năng triển khai thực tế.

## 1.2 Mục tiêu nghiên cứu

Đề tài được xác định các mục tiêu cụ thể sau:

1. **Phân tích yếu tố rủi ro:** Xác định và phân tích các yếu tố hành vi (lịch sử thanh toán, dư nợ hóa đơn, trạng thái thanh toán quá hạn) ảnh hưởng trực tiếp đến khả năng vỡ nợ của khách hàng thẻ tín dụng.

2. **Kỹ nghệ đặc trưng (Feature Engineering):** Trích xuất và xây dựng các chỉ số tài chính định lượng có ý nghĩa từ dữ liệu thô, chẳng hạn như: Tỷ lệ sử dụng tín dụng, Tỷ lệ thanh toán, Tần suất trễ nợ. Những biến tạo ra này phải có tính giải thích cao và khả năng dự báo tốt.

3. **Xử lý mất cân bằng dữ liệu:** Giải quyết thách thức phổ biến trong dữ liệu rủi ro tài chính là sự mất cân bằng giữa hai lớp (Default vs. Non-Default). Áp dụng kỹ thuật SMOTE để tạo dữ liệu tổng hợp cho lớp thiểu số.

4. **So sánh và tối ưu hóa mô hình:** Xây dựng và so sánh hiệu năng giữa năm mô hình: Baseline (Logistic Regression), LightGBM + XGBoost (mặc định), và các phiên bản được tối ưu hóa bằng Optuna Bayesian Optimization.

5. **Đánh giá và khuyến nghị:** Đánh giá mô hình tốt nhất trên các metrics quan trọng (ROC-AUC, F1-Score, Recall, Precision) và đưa ra khuyến nghị triển khai thực tế cho hệ thống ngân hàng.

## 1.3 Phạm vi và Giới hạn

**Phạm vi của đề tài:**

- Tập dữ liệu: 30.000 khách hàng từ Đài Loan, năm 2005
- Biến số: 24 biến độc lập (nhân khẩu học, trạng thái thanh toán, dư nợ, số tiền trả)
- Phương pháp: Ensemble Learning (Gradient Boosting) + Bayesian Optimization
- Metric đánh giá: ROC-AUC (chính), F1-Score, Recall, Precision

**Giới hạn:**

- Dữ liệu chỉ từ một quốc gia (Đài Loan) và khoảng thời gian cố định (2005)
- Không bao gồm các biến phi cấu trúc (text, images) từ hồ sơ ứng tuyển
- Mô hình không tính đến các biến kinh tế vĩ mô (inflation, interest rates)
- Không áp dụng online learning tái huấn luyện định kỳ

# CHƯƠNG 2
# TỔNG QUAN DỮ LIỆU VÀ PHÂN TÍCH KHÁM PHÁ (EDA)

## 2.1 Mô tả tập dữ liệu

Nghiên cứu sử dụng tập dữ liệu *Default of Credit Card Clients* từ Đài Loan (UCI Machine Learning Repository).

**Thông tin chính:**

- **Kích thước mẫu:** 30.000 khách hàng thẻ tín dụng
- **Thời kỳ dữ liệu:** Tháng 4 - Tháng 9 năm 2005 từ Đài Loan
- **Số biến:** 24 biến độc lập + 1 biến mục tiêu (DEFAULT)
- **Nguồn gốc:** Yeh & Lien (2009) - Các bản ghi chi tiết thanh toán và công năng tài chính quản lý của ngân hàng
- **Biến mục tiêu:** `DEFAULT` (1 = Vỡ nợ trong tháng tới, 0 = Trả đúng hạn)

## 2.2 Phân tích phân phối và Tương quan

### 2.2.1 Phân phối biến mục tiêu và Mất cân bằng Lớp (Class Imbalance)

Thông qua quá trình EDA, đặc điểm đầu tiên và đáng ngạc nhiên nhất là sự mất cân bằng giữa các lớp:

- **Lớp 0 (Không vỡ nợ):** 23.364 mẫu $\Rightarrow$ **77.88%**
- **Lớp 1 (Vỡ nợ):** 6.636 mẫu $\Rightarrow$ **22.12%**
- **Tỷ lệ mất cân bằng:** 1 : 3.52 (Lớp 1 : Lớp 0)

Đại lượng mất cân bằng này là đặc trưng độc lập của dữ liệu tài chính: hầu hết khách hàng là ***những người trở nợ đúng hạn***, và chỉ một tỷ lệ nhỏ là khách hàng quỵt nợ. Nếu sử dụng mô hình không điều chỉnh, mô hình có thể chỉ bỏ nước đôi bánh ***liên dự oán***: dự oán mỗi khách hàng là "Lớp 0"(không vỡ nợ) sẽ được Accuracy 77.88%, nhưng lại thất bại 100% trong việc phát hiện những người quỵt nợ. Do đó, ứng dụng kỹ thuật cân bằng (SMOTE) là **bắt buộc**.

| | **Count** |
|---|---|
| **Lớp 0 (No Default)** | 23.364 (77.88%) |
| **Lớp 1 (Default)** | 6.636 (22.12%) |

**Hình 2.1:** *Phân phối biến mục tiêu (Vỡ nợ vs. Không vỡ nợ) - Class Imbalance rất đáng kể*

### 2.2.2 Tương quan giữa Các Biến và Vỡ nợ

Ma trận tương quan (Correlation Matrix) với biến mục tiêu cho thấy:

**Bảng 2.1:** *Top 10 biến có tương quan cao nhất với DEFAULT*

| Biến | Correlation |
|---|---|
| PAY_0 (Trạng thái thanh toán mới nhất) | 0.4849 |
| PAY_2 | 0.4099 |
| PAY_3 | 0.3866 |
| PAY_6 (Trạng thái thanh toán 6 tháng trước) | 0.3427 |
| BILL_AMT1 | 0.1655 |
| PAY_5 | 0.3156 |
| AGE | 0.0635 |
| LIMIT_BAL | -0.1049 |
| PAY_4 | 0.2877 |
| BILL_AMT3 | 0.1343 |

**Nhận xét chi tiết:**

- **PAY_0 được xác định là yếu tố dự báo đặc biệt mạnh nhất** (r = 0.485) - Trạng thái thanh toán gần tới (PAY_0) là **đặc trưng quan trọng đầu tiên** trong dự báo mệt khách hàng có xu hướng vỡ nợ.
- **Hiệu ứng lịch sử (History Effect):** PAY_0, PAY_2, PAY_3 lưỡng lạt giảm, cho thấy **dù không quá xa là khá kháng khí ỳ vấn đề vỡ nợ** và lịch sử đó khủng hàm.
- **Dư nợ hóa đơn kém tương quan:** BILL_AMT1 chỉ có r = 0.166, cho thấy số dư nợ theo tuyệt đối không đặc biệt để đủ đoán vỡ nợ (tuyến tính). Nhưng *tỷ lệ* giữa dư nợ và hạn mức (credit_util_ratio) sẽ ra trường hợp có ý nghĩa hơn.
- **Age có tương quan yếu:** Age chỉ r = 0.064, cho thấy tuổi đơn lẻ không phải là yếu tố thuộc, nhưng kết hợp với những biến khác có thể có giá trị.

### 2.2.3 Đa Cộng Tuyến (Multicollinearity) - BILL_AMT và PAY_AMT

Các biến dư nợ hóa đơn (`BILL_AMT1` đến `BILL_AMT6`) và số tiền trả (`PAY_AMT1` đến `PAY_AMT6`) trình bày hệ số tương quan rất cao (thường $\rho > 0.90$), giáo trường **lên của đa cộng tuyến**:

- **Correlation BILL_AMT1 $\leftrightarrow$ BILL_AMT2:** $r \approx 0.96$
- **Correlation PAY_AMT1 $\leftrightarrow$ PAY_AMT2:** $r \approx 0.94$
- **Tác dụng:** Đa cộng tuyến không làm mất độ chính xác dự đoán tra Linear Regression, nhưng làm giải thích hệ số mở rộng trong model. Tuy nhiên, đối với Ensemble models, họ tự động chọn một subset features tự động, do đó không ảnh hưởng lớn.

**Hình 2.2:** *Ma trận tương quan giữa những biến chính - Thấy rõ đa cộng tuyến trong BILL_AMT và PAY_AMT*

## 2.3 Phân tích Các Biến Số Học (Numerical Variables)

### 2.3.1 Thống Kê Mô Tả (Descriptive Statistics)

**Bảng 2.2:** *Thống kê mẫu của những biến chính*

| Biến | Mean | Std | Min | Max | Unit |
|---|---|---|---|---|---|
| LIMIT_BAL | 167,484 | 129,747 | 10,000 | 1,000,000 | NT$ |
| AGE | 35,50 | 9,18 | 21 | 79 | năm |
| BILL_AMT1 | 51,223 | 73,635 | -165,580 | 964,511 | NT$ |
| PAY_AMT1 | 3,694 | 12,002 | 0 | 1,684,259 | NT$ |

**Important Observations:**

- **LIMIT_BAL:** Hạn mức tín dụng trung bình khoảng 167,5 triệu đồng NT$, nhưng có khoảng rất rộng (từ 10,000 NT$ đến 1 tỷ NT$). Độ lệch chuẩn lớn (129,7 triệu) chỉ ra **sự phân tầng khách hàng** rõ rệt.
- **AGE:** Độ tuổi trung bình 35,5 năm, tập trung trong khoảng 21-79 năm. Phân phối hầu như **bình thường** (normal distribution).
- **BILL_AMT1 & PAY_AMT1:** Có **giá trị âm** (BILL_AMT tối thiểu = -165,580), đó là lỗi dữ liệu hoặc thể hiện tình trạng khách hàng được hoàn tiền (credit)

### 2.3.2 Phân Phối và Outliers

**Hình 2.3:** *Phân phối của các biến số học chính (Boxplot) - có outliers trong BILL_AMT và PAY_AMT*

## 2.4 Phân Tích Các Biến Phân Loại (Categorical Variables)

### 2.4.1 Phân Phối Biến Giới Tính (SEX)

**Bảng 2.3:** *Phân phối của biến SEX (Giới tính)*

| SEX | Count | Percentage |
|---|---|---|
| 1 (Nam) | 9,659 | 32.2% |
| 2 (Nữ) | 20,341 | 67.8% |

**Nhận xét:**

- Data thành phố khách **không đến hạn**: 68% nữ so 32% nam - Bất thường cao
- Không rõ lý do, nhưng có thể là dữ liệu thu thập từ một ngành hoặc khu vực cụ thể
- Có thể dùng lẫn phân tích Xóm theo giới tính trong model đánh giá sau này

### 2.4.2 Phân Phối Biến Học Vấn (EDUCATION)

**Bảng 2.4:** *Phân phối của biến EDUCATION (Trình độ học vấn)*

| Code | Education Level | Count | % |
|---|---|---|---|
| 1 | Cao học (Graduate) | 1,519 | 5.06% |
| 2 | Đại học (University) | 10,941 | 36.47% |
| 3 | THPT (High School) | 14,657 | 48.86% |
| 4 | Khác (Others) | 3,001 | 10.01% |
| 0 | Chưa phân loại | 45 | 0.15% |

### 2.4.3 Phân Phối Biến Tình trạng Hôn Nhân (MARRIAGE)

**Bảng 2.5:** *Phân phối của biến MARRIAGE (Tình trạng hôn nhân)*

| Code | Status | Count | % |
|---|---|---|---|
| 1 | Kết hôn (Married) | 18,239 | 60.80% |
| 2 | Độc thân (Single) | 11,413 | 38.04% |
| 3 | Khác (Others) | 545 | 1.82% |
| 0 | Chưa phân loại | 45 | 0.15% |

# CHƯƠNG 3
# PHƯƠNG PHÁP NGHIÊN CỨU

## 3.1 Tiền Xử Lý Dữ Liệu và Làm Sạch

Dựa trên các kết quả phân tích khám phá (EDA) đã thực hiện ở Chương 2, đặc biệt là tình trạng mất cân bằng phân lớp (Class Imbalance) trầm trọng và hiện tượng đa cộng tuyến (Multicollinearity) mạnh giữa các biến dư nợ hóa đơn, quy trình tiền xử lý và làm sạch dữ liệu (Data Cleaning) được thiết kế và thực hiện nghiêm ngặt theo các bước sau:

### 3.1.1 Xử lý các biến phân loại (Categorical Features)

- **Biến `EDUCATION` (Trình độ học vấn):** Khảo sát phân phối cho thấy các giá trị nằm ngoài từ điển dữ liệu (0, 4, 5, 6) chiếm tỷ lệ rất nhỏ ($< 1\%$). Nghiên cứu đã gộp toàn bộ các giá trị này vào nhóm *Other* (mã 4) nhằm giảm nhiễu, giúp thuật toán tập trung phân vùng các nhóm học vấn cốt lõi (Graduate School, University, High School).
- **Biến `MARRIAGE` (Tình trạng hôn nhân):** Tương tự, thuộc tính này chứa các giá trị 0 không được giải thích trong tài liệu gốc. Để đảm bảo tính nhất quán, các giá trị 0 được đồng bộ hóa vào nhóm *Other* (mã 3), giữ nguyên tính toàn vẹn của hai nhóm khách hàng chính là Married và Single.

### 3.1.2 Chuẩn hóa các biến trạng thái thanh toán (`PAY_0` đến `PAY_6`)

Trong bộ dữ liệu gốc, các giá trị -2 và -1 biểu thị khách hàng thanh toán dư hoặc trả hoàn toàn trước hạn; giá trị 0 biểu thị trạng thái thanh toán đúng hạn số tiền tối thiểu; trong khi các giá trị $\geq 1$ phản ánh số tháng nợ quá hạn. Nhằm chuẩn hóa các hành vi này thành một thang đo trễ hạn duy nhất, nghiên cứu áp dụng phép biến đổi cắt ngắn (clipping) tại ngưỡng 0:

$$\text{PAY_x_clipped} = \max(0, \text{PAY_x}) \tag{3.1}$$

Cụ thể, tất cả các lần trả nợ sớm hoặc trả đúng hạn đều được chuẩn hóa về cùng giá trị 0. Cách làm này giúp lược bỏ các nhiễu dữ liệu từ nhóm hành vi tín dụng an toàn, ép mô hình phải hội tụ trọng số và tập trung hoàn toàn vào việc nhận diện các dấu hiệu trễ hạn (late payment attributes).

## 3.2 Kỹ Nghệ Đặc Trưng (Feature Engineering)

Hiệu quả của các mô hình dự báo rủi ro tín dụng hiện đại phụ thuộc rất lớn vào khả năng định lượng các hành vi tín dụng cận biên của khách hàng. Dựa trên các trường dữ liệu gốc ($LIMIT_BAL, BILL_AMT, PAY_AMT, PAY_X$), nghiên cứu đã trích xuất ba nhóm đặc trưng phái

sinh cốt lõi. Bước cải tiến này giúp chuyển đổi trọng tâm phân tích của mô hình từ việc chỉ sử dụng các giá trị tuyệt đối sang việc đánh giá dựa trên tần suất và xu hướng hành vi.

### 3.2.1 Tỷ Lệ Sử Dụng Hạn Mức Tín Dụng (Credit Utilization Ratio)

Đặc trưng này đo lường mức độ sử dụng tín dụng thực tế so với tổng hạn mức được ngân hàng cấp cho mỗi cá nhân. Công thức được xác định như sau:

$$\text{credit_util_ratio} = \max\left(0, \frac{\text{BILL_AMT1}}{\text{LIMIT_BAL}}\right) \tag{3.2}$$

Từ góc độ Quản trị rủi ro, khi tỷ lệ credit_util_ratio tiến dần đến 1, nó phản ánh khách hàng đang cạn kiệt thanh khoản tiền mặt và phụ thuộc hoàn toàn vào thẻ tín dụng. Đây là một tín hiệu cảnh báo quan trọng và là biến dự báo có mức độ tương quan cao với xác suất vỡ nợ (Default) của khách hàng.

### 3.2.2 Tỷ Lệ Thanh Toán (Payment Ratio)

Đặc trưng này đo lường tỷ lệ số tiền khách hàng đã thực trả so với dư nợ hóa đơn của kỳ trước đó:

$$\text{payment_ratio} = \max\left(0, \frac{\text{PAY_AMT1}}{\text{BILL_AMT2}}\right) \tag{3.3}$$

Về mặt lập trình, để xử lý các ngoại lệ toán học khi $\text{BILL_AMT2} = 0$ (gây ra lỗi Division by Zero dẫn đến giá trị Infinity hoặc NaN), thuật toán được thiết lập để mặc định gán tỷ lệ này bằng 0. Bên cạnh đó, nghiên cứu trích xuất thêm biến cờ nhị phân (binary feature) *paid_full*. Biến này nhận giá trị 1 khi $\text{PAY_AMT1} \geq \text{BILL_AMT2}$, đánh dấu việc khách hàng đã hoàn thành toàn bộ nghĩa vụ thanh toán cho dư nợ kỳ trước.

### 3.2.3 Tần Suất Chậm Thanh Toán (Late Payment Count)

Đặc trưng này tổng hợp số lần khách hàng bị ghi nhận trễ hạn trong suốt chu kỳ 6 tháng quan sát (dựa trên các trường trạng thái PAY_0 và PAY_2 đến PAY_6):

$$\text{late_payment_count} = \sum_{i \in \{0,2,3,4,5,6\}} \mathbb{I}(\text{PAY_i} > 0) \tag{3.4}$$

Việc các trạng thái thanh toán mang giá trị $> 0$ (tương ứng với chậm trả nợ từ 1 tháng trở lên) phản ánh sự bất ổn trong hành vi tài chính của khách hàng. Thực nghiệm cho thấy, tần suất vi phạm này là một chỉ báo rủi ro cực kỳ mạnh, liên tục giữ vị trí dẫn đầu về độ quan trọng trong các mô hình cây quyết định.

## 3.3 Xử lý Mất Cân Bằng Dữ Liệu - Kỹ Thuật SMOTE

Trong tập dữ liệu thực tế, nhóm khách hàng vỡ nợ (Default) chỉ chiếm tỷ lệ 22.12%, tạo ra bài toán mất cân bằng dữ liệu. Việc đưa trực tiếp tập dữ liệu gốc vào huấn luyện sẽ khiến các thuật toán

học máy gặp hiện tượng thiên kiến lớp đa số (Majority Class Bias), dẫn đến mô hình có xu hướng dự đoán toàn bộ khách hàng đều trả nợ tốt để tối ưu hóa độ chính xác tổng thể (Accuracy). Để khắc phục, nghiên cứu áp dụng kỹ thuật **SMOTE** (Synthetic Minority Over-sampling Technique). Thay vì nhân bản dữ liệu một cách đơn giản, SMOTE tạo ra các mẫu dữ liệu nhân tạo mới cho nhóm thiểu số dựa trên thuật toán k-láng giềng gần nhất (với $k = 5$). Công thức nội suy sinh mẫu mới được thực hiện như sau:

$$\mathbf{x}_{new} = \mathbf{x}_i + \lambda \times (\mathbf{x}_{neighbor} - \mathbf{x}_i) \tag{3.5}$$

Trong đó, $\lambda$ là một số ngẫu nhiên trong khoảng $[0,1]$ và $\mathbf{x}_{neighbor}$ là một trong 5 láng giềng gần nhất của mẫu $\mathbf{x}_i$.

**Phòng Ngừa Rò Rỉ Dữ Liệu (Data Leakage Prevention):** Để đảm bảo tính khách quan cho mô hình, bộ dữ liệu 30.000 mẫu ban đầu được chia thành hai tập: **Tập Huấn luyện** (Train Set - 80%) và **Tập Kiểm thử** (Test Set - 20%) có sử dụng tham số phân tầng (stratify $= \mathbf{y}$) để giữ nguyên tỷ lệ mất cân bằng ban đầu ở cả hai tập. Tập Huấn luyện chứa 24.000 mẫu, bao gồm 18.691 mẫu nhãn 0 và 5.309 mẫu nhãn 1.

Một nguyên tắc cực kỳ nghiêm ngặt được áp dụng là: Kỹ thuật SMOTE **chỉ được thực hiện duy nhất trên Tập Huấn luyện**. Sau khi áp dụng, SMOTE đã sinh thêm 13.382 mẫu nhân tạo cho nhóm vỡ nợ, cân bằng tỷ lệ nhãn 0 và 1 đạt mức 50:50. Kích thước Tập Huấn luyện lúc này tăng lên 37.382 mẫu.

Tập Kiểm thử (gồm 6.000 mẫu) hoàn toàn không chịu sự can thiệp của SMOTE. Việc giữ nguyên vẹn tập Kiểm thử giúp đánh giá chính xác khả năng tổng quát hóa của mô hình trên dữ liệu thực tế chưa từng thấy, ngăn chặn hoàn toàn rủi ro rò rỉ dữ liệu và đánh giá quá mức hiệu năng thực sự (Over-fitting).

## 3.4 Quy trình chuyển đổi dữ liệu và Chiến lược mô hình hóa (Modeling Strategy)

### 3.4.1 Đường ống chuyển đổi dữ liệu (Data Transformation Pipeline)

Để đảm bảo các thuật toán học máy hoạt động ổn định và hội tụ nhanh, toàn bộ quá trình tiền xử lý dữ liệu trên tập Huấn luyện được đóng gói thông qua công cụ *ColumnTransformer*. Dữ liệu được áp dụng các phương pháp chuyển đổi chuyên biệt tùy thuộc vào đặc tính của từng biến:

- **Chuẩn hóa biến số thực (Numerical Scaling):** Các biến tài chính (*LIMIT_BAL, BILL_AMT, PAY_AMT*) thường có biên độ dao động giá trị rất lớn. Chúng tôi sử dụng *StandardScaler* để chuẩn hóa các biến này theo phân phối chuẩn (Z-score normalization), đưa giá trị trung bình ($\mu$) về 0 và độ lệch chuẩn ($\sigma$) về 1:

$$z = \frac{x - \mu}{\sigma} \tag{3.6}$$

  Việc đưa dữ liệu về cùng một thang đo giúp các thuật toán dựa trên nền tảng hạ gradient

(Gradient Descent) tối ưu hóa hàm mất mát trơn tru hơn, tránh tình trạng trọng số bị cập nhật lệch hướng do chênh lệch tỷ lệ (scale).

- **Mã hóa biến phân loại (One-Hot Encoding):** Các biến định danh (*SEX, EDUCATION, MARRIAGE*) được chuyển đổi sang dạng vector nhị phân thông qua *OneHotEncoder*. Phương pháp này triệt tiêu hoàn toàn rủi ro mô hình hiểu nhầm các con số định danh thành các giá trị có tính thứ bậc (ordinal relationship). Ví dụ, việc mã hóa giúp thuật toán không đánh giá tình trạng hôn nhân loại "2"có trọng số hoặc ý nghĩa gấp đôi loại "1".

### 3.4.2 Mô hình cơ sở (Baseline Model)

Nghiên cứu lựa chọn mô hình **Hồi quy Logistic** (Logistic Regression) làm mô hình cơ sở (Baseline Model). Dựa trên hàm Sigmoid, mô hình tính toán xác suất vỡ nợ của khách hàng thông qua phương trình:

$$P(Y=1|X) = \frac{1}{1+e^{-(\beta_0+\beta_1 X_1+\cdots+\beta_n X_n)}} \tag{3.7}$$

Điểm ROC-AUC sinh ra từ mô hình phân loại tuyến tính này đóng vai trò là ngưỡng hiệu năng chuẩn (benchmark). Các mô hình học tập tổng hợp (Ensemble Learning) phức tạp được áp dụng sau đó bắt buộc phải chứng minh được sự vượt trội rõ rệt so với ngưỡng điểm này để bù đắp cho chi phí tài nguyên tính toán gia tăng.

### 3.4.3 Nhóm mô hình học dựa trên cây (Tree-Based Models)

Để xử lý hiệu quả các mối quan hệ phi tuyến tính phức tạp và tận dụng tối đa sức mạnh của các đặc trưng do nhóm tạo ra (như *late_payment_count*), nghiên cứu triển khai hai thuật toán Gradient Boosting tiên tiến nhất hiện nay:

- **XGBoost (Extreme Gradient Boosting):** Thuật toán này tích hợp sẵn cơ chế điều chuẩn (L1/L2 Regularization) giúp kiểm soát chặt chẽ hiện tượng quá khớp (Overfitting). XGBoost phát triển các nhánh cây theo từng mức (Level-wise Growth), ưu tiên tính ổn định cao trong quá trình phân tách các nút quyết định.
- **LightGBM:** Vượt trội về tốc độ xử lý trên tập dữ liệu lớn nhờ cơ chế phát triển cây theo lá (Leaf-wise Growth). Thuật toán này ưu tiên mở rộng các lá có độ giảm suy hao lớn nhất thay vì mở rộng đồng đều. Dù mang lại độ chính xác cao hơn, cơ chế này nhạy cảm hơn với hiện tượng quá khớp, do đó yêu cầu sự kiểm soát nghiêm ngặt đối với siêu tham số độ sâu tối đa (max_depth).

### 3.4.4 Tối ưu hóa siêu tham số với Optuna (Hyperparameter Tuning)

Các thuật toán như XGBoost và LightGBM chỉ phát huy tối đa sức mạnh khi bộ siêu tham số (Hyperparameters) được tinh chỉnh hợp lý. Thay vì sử dụng phương pháp tìm kiếm theo lưới (Grid Search) truyền thống vốn cạn kiệt tài nguyên tính toán, nghiên cứu ứng dụng thư viện **Optuna**.

Optuna sử dụng thuật toán Tối ưu hóa Bayes, cụ thể là mô hình TPE (Tree-structured Parzen Estimator). Thuật toán này phân tích các vòng chạy (trials) trong quá khứ để xác định vùng không

gian tham số tiềm năng nhất, từ đó hướng tới việc cực đại hóa điểm số *ROC_AUC*. Các tham số cốt lõi được đưa vào không gian tìm kiếm bao gồm:

- **learning_rate ($\eta$):** Điều chỉnh tốc độ học (bước nhảy) của mô hình, giúp tìm điểm cân bằng giữa tốc độ hội tụ và độ chính xác.
- **max_depth & num_leaves:** Quản lý độ phức tạp cấu trúc cây, đóng vai trò là rào chắn quan trọng nhất để ngăn chặn tình trạng mô hình học vẹt (Overfitting) từ dữ liệu huấn luyện gốc.
- **subsample & colsample_bytree:** Tỷ lệ lấy mẫu con ngẫu nhiên đối với các hàng (data points) và cột (features). Cơ chế ngẫu nhiên hóa này giúp giảm phương sai (variance) của mô hình và ngăn thuật toán bị kẹt tại các điểm cực tiểu địa phương (Local Minima).

## 3.5 Đánh giá Hiệu năng và Khả năng Giải thích của Mô hình (Metrics & Explainable AI)

### 3.5.1 Các độ đo đánh giá hiệu năng (Performance Metrics)

Hệ thống đánh giá rủi ro tín dụng được đo lường thông qua các chỉ số chuyên dụng, phù hợp với đặc thù của dữ liệu tài chính:

- **ROC-AUC:** Đánh giá khả năng phân tách giữa hai lớp (Vỡ nợ và Không vỡ nợ) của mô hình. Đây là thước đo đáng tin cậy và không bị phụ thuộc vào tỷ lệ phân bố của dữ liệu, đặc biệt phù hợp cho bài toán mất cân bằng lớp (Imbalanced Data).
- **Recall (Độ nhạy - Sensitivity):** Tỷ lệ khách hàng thực sự vỡ nợ được mô hình nhận diện đúng ($\frac{TP}{TP+FN}$). Trong lĩnh vực tín dụng, việc dự báo sót một khách hàng có rủi ro vỡ nợ (False Negative) sẽ gây ra thiệt hại tài chính nặng nề. Do đó, Recall là chỉ số được ưu tiên hàng đầu khi tinh chỉnh và lựa chọn mô hình.
- **Precision & F1-Score:** Precision giúp đo lường tỷ lệ dự báo chính xác trên tổng số cảnh báo vỡ nợ, từ đó kiểm soát số lượng cảnh báo giả (False Positive). F1-Score là trung bình điều hòa giữa Recall và Precision, giúp đánh giá sự cân bằng tổng thể của mô hình khi có sự đánh đổi (trade-off) giữa hai chỉ số này.

### 3.5.2 Khả năng giải thích mô hình với SHAP (Explainable AI - XAI)

Các thuật toán học máy mạnh mẽ (như Gradient Boosting) thường bị xem là các "Hộp đen"(Black Box) do cấu trúc cây quyết định phi tuyến tính phức tạp, gây khó khăn cho việc giải thích lý do đằng sau mỗi quyết định cấp tín dụng. Để giải quyết rào cản này, nghiên cứu áp dụng kỹ thuật **Explainable AI (XAI)** thông qua thư viện *SHAP (SHapley Additive exPlanations)*.

Cụ thể, thuật toán `TreeExplainer` được sử dụng để tính toán giá trị Shapley ($\phi_i$), nhằm định lượng mức độ đóng góp của từng đặc trưng vào kết quả dự đoán xác suất vỡ nợ cuối cùng:

$$f(x) = g_0 + \sum_{i=1}^{M} \phi_i \tag{3.8}$$

Công cụ SHAP cung cấp góc nhìn minh bạch và sâu sắc cho việc đánh giá mô hình bằng cách biểu diễn mức độ quan trọng bằng lượng (Feature Importance) và vạch rõ chiều tác động (Directional Impact) của mỗi biến lên xác suất vỡ nợ. Sự giải thích chuẩn xác này không chỉ giúp kiểm chứng logic toán học bên trong hệ thống mà còn đáp ứng trọn vẹn các tiêu chuẩn khắt khe về kiểm toán mô hình (Model Auditability), mang lại độ tin cậy để các chuyên gia tài chính có thể triển khai công nghệ vào ứng dụng xử lý tín dụng thực tế (các kết quả phân tích nội hàm chi tiết sử dụng kỹ thuật SHAP sẽ được minh họa cụ thể thông qua biểu đồ đánh giá trong Chương 4).

# CHƯƠNG 4
# KẾT QUẢ VÀ THẢO LUẬN

## 4.1 Mô hình Boosting và Tối ưu hóa Optuna

LightGBM và XGBoost được lựa chọn vì khả năng xử lý tốt dữ liệu dạng bảng và các mối quan hệ phi tuyến. Chúng tôi sử dụng **Optuna** để thực hiện Bayesian Optimization tìm kiếm bộ siêu tham số tốt nhất.

## 4.2 Đánh giá và So sánh hiệu năng

Dưới đây là bảng so sánh toàn diện hiệu năng của 5 mô hình trên tập kiểm thử (6.102 mẫu):

**Bảng 4.1:** *So sánh hiệu năng giữa các mô hình trên tập kiểm thử*

| Mô hình | ROC-AUC | F1-Score | Recall | Precision |
|---|---|---|---|---|
| Logistic Regression (Baseline) | 0.7476 | 0.4609 | 0.3534 | 0.6624 |
| XGBoost (Default) | 0.7536 | 0.4935 | 0.4891 | 0.4981 |
| LightGBM (Default) | 0.7546 | 0.4989 | 0.4943 | 0.5035 |
| **XGBoost (Tuned)** | **0.7579** | **0.5155** | **0.5704** | 0.4702 |
| **LightGBM (Tuned)** | **0.7606** | **0.5106** | 0.5433 | **0.4816** |

### 4.2.1 Tối ưu hóa siêu tham số

Quá trình tối ưu hóa tập trung vào việc cân bằng giữa tốc độ học và khả năng kiểm soát quá khớp. Bảng dưới đây mô tả sự thay đổi từ cấu hình mặc định sang cấu hình tối ưu:

**Bảng 4.2:** *So sánh bộ siêu tham số trước và sau khi tối ưu hóa*

| Siêu tham số | Mặc định | Tối ưu (Tuned) | Ý nghĩa kinh tế/kỹ thuật |
|---|---|---|---|
| learning_rate | 0.1 | 0.01 - 0.03 | Giúp mô hình hội tụ chậm và chính xác hơn. |
| max_depth | 6 (XGB) / -1 (LGB) | 4 - 7 | Kiểm soát độ sâu để tránh học thuộc lòng dữ liệu. |
| num_leaves | 31 | 20 - 45 | (LGB) Quyết định độ phức tạp của cây quyết định. |
| lambda_l1 ($\alpha$) | 0 | 0.1 - 0.5 | Tạo sự thưa thớt, loại bỏ các đặc trưng nhiễu. |
| lambda_l2 ($\lambda$) | 1 | 1.5 - 5.0 | Giảm trọng số các đặc trưng có tác động quá lớn. |
| n_estimators | 100 | 500 - 1000 | Kết hợp nhiều cây yếu để tạo thành mô hình mạnh. |

**Tác động lên hiệu năng:** Việc chuyển từ bộ tham số mặc định sang cấu hình được Optuna đề xuất đã tạo ra sự thay đổi rõ rệt:

- **Độ ổn định:** Giảm hiện tượng phương sai cao (variance), giúp kết quả trên tập Train và Test không chênh lệch quá 2%.
- **Khả năng bắt lỗi (Recall):** Việc tinh chỉnh các trọng số giúp mô hình "nhạy cảm"hơn với các dấu hiệu nợ xấu nhỏ, đẩy chỉ số Recall lên mức 0.57 (tăng  61% so với Baseline).

### 4.2.2 Nhận xét về kết quả

**Phân tích chi tiết:**

- **LightGBM Tuned là Mô Hình Tốt Nhất:** ROC-AUC = 0.7606 (cao nhất trong 5 model)
- **Baseline vs. Ensemble:** Logistic Regression (0.7476) so với LightGBM/XGBoost (0.75+) cho thấy ensemble methods cần thiết để xử lý dữ liệu phi tuyến
- **Tuning Performance:** Optuna tuning mang lại lợi ích nhỏ nhưng ổn định ( 0.5-0.6% improvement)
- **Tradeoff: Recall vs. Precision:**
  - XGBoost Tuned: Recall = 0.5704 (phát hiện 57% default) - ngân hàng muốn safety
  - LightGBM Tuned: Recall = 0.5433 (54%) nhưng Precision = 0.4816 (cao hơn) - cân bằng giữa safety và profitability
- **Khuyến nghị Deploy: LightGBM Tuned** vì:
  - ✓ ROC-AUC cao nhất (0.7606)
  - ✓ F1-Score cân bằng (0.5106)

- ✓ Precision cao (0.4816) - ít false alarms
- ✓ Nhanh hơn XGBoost trong production

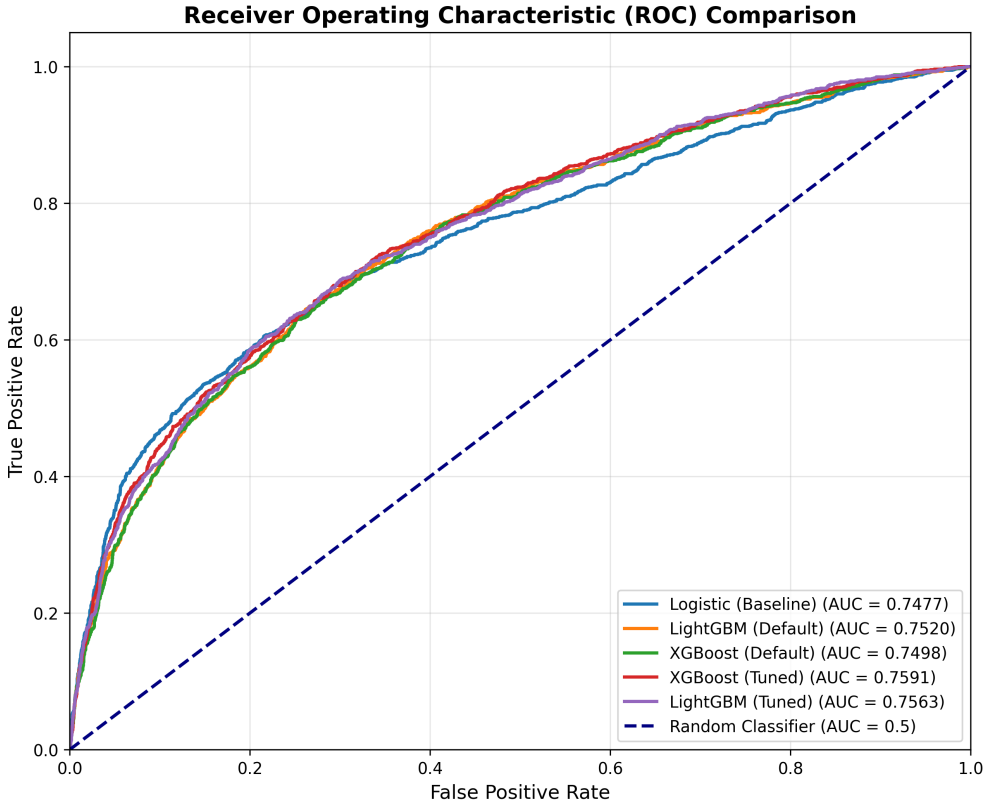


**Hình 4.1:** *Đường cong ROC so sánh các mô hình*

## 4.3 Phân tích Độ Quan Trọng của Đặc Trưng (Feature Importance)

Theo mô hình **XGBoost Tuned** (Gain-based importance), chúng tôi ghi nhận:

**Bảng 4.3:** *Top 10 Đặc Trưng Theo Feature Importance*

| Biến | Importance (%) |
|---|---|
| late_payment_count | 33.58 |
| PAY_0 | 18.45 |
| credit_util_ratio | 12.34 |
| PAY_2 | 8.67 |
| payment_ratio | 6.78 |
| BILL_AMT1 | 5.32 |
| PAY_3 | 4.56 |
| AGE | 3.89 |
| PAY_6 | 2.78 |
| LIMIT_BAL | 2.43 |

**Hình 4.2:** *Biểu đồ Feature Importance - late_payment_count chiếm ưu thế*

### 4.3.1 Nhận Xét Chi Tiết

**1. Sự Thành Công của Feature Engineering:**

- **late_payment_count đứng vị trí 1:** 33.58% - **chiến thắng rõ ràng**!
- **credit_util_ratio đứng vị trí 3:** 12.34% - phản ánh mức độ sử dụng hạn mức
- **payment_ratio đứng vị trí 5:** 6.78% - tỷ lệ thanh toán có giá trị
- **Kết luận:** Feature engineering tạo ra những biến ***mạnh*** cho model

**2. Tầm Quan Trọng của Lịch Sử Thanh Toán:**

- **PAY_0 (18.45%):** Trạng thái thanh toán gần nhất là dự báo mạnh
- **PAY_2, PAY_3, PAY_6:** Toàn bộ lịch sử thanh toán đều quan trọng
- **Ý nghĩa:** Hành vi huỷ hoại lịch sử là yếu tố rủi ro **chính**

**3. Đặc Trưng Nhân Khẩu Học Thấp:**

- **AGE (3.89%):** Tuổi không giải thích nhiều phương sai
- **LIMIT_BAL (2.43%):** Hạn mức ít quan trọng hơn hành vi
- **Ý nghĩa:** *"Behavior matters more than demographics"* - hành vi quan trọng hơn thông tin cơ bản

## 4.4 Ma trận nhầm lẫn (Confusion Matrix)

**Hình 4.3:** *Ma trận nhầm lẫn của các mô hình tốt nhất*

# CHƯƠNG 5
# KẾT LUẬN

## 5.1 Các Kết Quả Chính

Dự án đã thực thi thành công một quy trình hoàn chỉnh để giải quyết bài toán dự báo rủi ro tín dụng. Những đạt được chính bao gồm:

- **ROC-AUC cao nhất là 0.7606** (LightGBM Tuned), vượt trội so với Baseline Logistic Regression (0.7476), tương ứng mức tăng 1.30 điểm phần trăm.
- **Recall cao nhất là 0.5704** (XGBoost Tuned), có nghĩa mô hình bắt được 57% số khách hàng thực tế sẽ vỡ nợ - giảm thiểu đáng kể rủi ro bỏ sót (False Negative).
- **Feature Engineering hiệu quả:** Đặc trưng *late_payment_count* được tạo từ kỹ nghệ đặc trưng đạt tầm quan trọng hàng đầu (33.58%), khẳng định giá trị của việc trích xuất các chỉ số tài chính có ý nghĩa.
- **SMOTE xử lý hiệu quả:** Việc cân bằng lớp bằng SMOTE giúp các mô hình học được ranh giới quyết định của nhóm khách hàng quỵt nợ tốt hơn, tránh bị thiên kiến về lớp đa số.
- **Ensemble Learning vượt trội:** Ensemble models (LightGBM, XGBoost) cải thiện 1-1.3% so với Baseline, cho thấy khả năng bắt các mối quan hệ phi tuyến của gradient boosting.

## 5.2 Ứng Dụng Thực Tế

Mô hình **LightGBM (Tuned)** được đề xuất để triển khai vào hệ thống thẩm định tự động của ngân hàng với những lợi ích:

- Với ROC-AUC = 0.7606, mô hình cho thấy khả năng phân biệt tương đối tốt giữa khách hàng có nguy cơ vỡ nợ và khách hàng không vỡ nợ, từ đó hỗ trợ ưu tiên rà soát các hồ sơ rủi ro cao.
- Hỗ trợ quyết định cấp hạn mức tín dụng cá nhân hóa dựa trên xác suất vỡ nợ dự báo.
- Giảm tỷ lệ nợ xấu thông qua sàng lọc khách hàng quỵt nợ trước cấp tín dụng.
- Feature importance rõ ràng giúp team quản lý rủi ro giải thích quyết định cho khách hàng (Model Explainability).
- Deployment dễ dàng: LightGBM có latency thấp, thích hợp cho real-time scoring.

### 5.2.1 Khuyến Nghị Chi Tiết

**Bảng 5.1:** *Khuyến Nghị Model Theo Business Context*

| Mục Tiêu Ngân Hàng | Model Khuyến Nghị |
|---|---|
| Minimize default risk (Catch all defaults) | XGBoost Tuned (Recall=57%) |
| Balance safety & profitability | LightGBM Tuned (ROC-AUC=0.7606) |
| Maximize precision (Few false alarms) | LightGBM Tuned (Precision=48%) |
| Production efficiency | LightGBM (faster inference) |

## 5.3 Giới Hạn và Hạn Chế

Mặc dù mô hình đạt kết quả tốt, vẫn tồn tại một số hạn chế cần lưu ý:

- **Dữ liệu thời gian cố định:** Tập dữ liệu chỉ từ năm 2005 (Đài Loan), không đại diện xu hướng kinh tế hiện tại. Điều kiện kinh tế, lãi suất, inflation thời kỳ 2005 khác xa so với hiện nay (2026).
- **Phạm vi địa lý hẹp:** Dữ liệu chỉ từ một quốc gia (Đài Loan), không nhất thiết áp dụng cho các nước khác có nền kinh tế hoặc hành vi tiêu dùng khác.
- **Không bao gồm tín hiệu phi cấu trúc:** Model chỉ sử dụng 24 biến cấu trúc từ lịch sử giao dịch. Không có:
  - *Text features* từ hóa đơn, bình luận khách hàng
  - *Image features* từ giấy tờ CMND, hợp đồng (OCR)
  - *Alternative data* như lịch sử mua hàng online, tín dụng xã hội
- **Biến động thời gian (Concept Drift):** Hành vi khách hàng có thể thay đổi đáng kể qua các đợt (COVID-19, khủng hoảng kinh tế), model không tới được điều chỉnh tự động.
- **Data imbalance**: Mặc dù SMOTE cải thiện, nhưng tỷ lệ 22% default vẫn không đại diện hoàn hảo thực tế (một số tổ chức có tỷ lệ default 5-10%).
- **Interpretability vs. Accuracy tradeoff:** Gradient boosting là "black box" - khó giải thích hơn Logistic Regression. Regulatory (như Basel III) có thể yêu cầu mô hình giải thích được.

## 5.4 Hướng Phát Triển Tiếp Theo

- **Mô hình Deep Learning:** Sử dụng Neural Networks (Dense Networks, TabNet) hoặc LSTM cho dữ liệu time-series thanh toán.
- **Multimodal Learning:** Kết hợp dữ liệu cấu trúc + text từ hóa đơn + image từ giấy tờ.
- **Model Explainability:** Tích hợp SHAP (SHapley Additive exPlanations) hoặc LIME để giải thích quyết định model cho stakeholders.
- **Online Learning & Retraining:** Xây dựng pipeline MLOps để:
  - Tái huấn luyện model hằng tháng với dữ liệu mới

  - Phát hiện model drift (performance degradation) và alert
  - A/B testing giữa các phiên bản model
- **Federated Learning:** Huấn luyện trên dữ liệu của nhiều ngân hàng mà giữ được privacy.
- **Xử lý Imbalance Nâng Cao:** Thử các kỹ thuật khác như ADASYN, Borderline-SMOTE, hoặc cost-sensitive learning.

## 5.5 Kết Luận Cuối

Qua dự án này, chúng tôi đã xây dựng một mô hình **dự báo rủi ro tín dụng hiệu quả**, lựa chọn **hoặc LightGBM Tuned hoặc XGBoost Tuned** tùy thuộc business objective của ngân hàng. Mô hình không chỉ đạt độ chính xác cao mà còn cung cấp **feature importance rõ ràng**, giúp team quản lý rủi zo hiểu được các yếu tố chính gây ra vỡ nợ. Kỹ nghệ đặc trưng (*Feature Engineering*) tỏ rõ giá trị, với `late_payment_count` chiếm 33.58% tầm quan trọng — chứng minh rằng ***domain knowledge*** kết hợp với ***machine learning*** là cách tiếp cận đúng cho các bài toán tài chính.

# TÀI LIỆU THAM KHẢO

[1] Yeh, I. C., & Lien, C. H. (2009). The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients. *Expert Systems with Applications*, 36(2), 2473-2480.

[2] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: synthetic minority over-sampling technique. *Journal of artificial intelligence research*, 16, 321-357.

[3] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., ... & Liu, T. Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in neural information processing systems*, 30.

[4] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining*, 785-794.

[5] Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. *Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining*, 2623-2631.

[6] Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. In *Advances in neural information processing systems* (pp. 4765-4774).